

BC Agent Desktop — 企业自建 AI Agent 底座方案

版本：v2.0 | 2026-08-21

密级：内部

一、当前形势：我们为什么需要自建

1.1 外部平台正在收紧

目前团队开发和业务部门都在使用 **Trae Work** 作为 AI 助手（当前以开发为主，少数业务部门已开始使用，后续预计将扩展到 50 人以上）。Trae Work 的政策变化非常明确：

时间节点	变化
早期	完全免费，支持绑定自己的 DeepSeek API Key
现在	引入积分制，每日签到 200 积分 $\approx$ 10 个任务，高峰期排队严重
2026-08-17	DeepSeek 全线涨价 4.5 倍 ，即使绑定自己的 Key，成本也大幅上升
可预见未来	免费额度只会越来越少，最低付费套餐 ¥49.9/月/人，并且对于重度用户来说至少需要99的套餐

关键问题：Trae Work 的定价权完全掌握在别人手里，今天涨价、明天限流、后天改规则，我们没有议价能力，也没有替代方案。**更关键的是，业务部门也在逐步接入，如果现在不布局，未来 50 人甚至更多人的使用成本将是一笔不小的开支。**

1.2 不只是成本问题，更是战略问题

风险维度	说明
供应商锁定	团队习惯和 workflows 深度绑定 Trae Work，一旦平台政策变化，切换成本极高
排队降效	高峰期排队严重，直接影响开发效率
数据不可控	即使绑自己的 Key，平台侧仍能看到你的使用行为和数据
功能受限	只能做编程辅助，无法扩展到业务系统对接、定时任务等企业场景
规模不经济	团队每增加一人，多一份 ¥49.9/月，人越多成本线性增长

1.3 市场窗口：DeepSeek 开源生态成熟了

DeepSeek 官方在 2026 年开源了 **deepseek-harness (dsh)** ——一个成熟的插件化 Agent 运行时。这意味着：

- 我们不再需要从零造轮子，dsh 提供了完整的会话管理、技能系统、LLM 集成
- 它是**开源软件**，不受任何商业平台政策影响
- 它的**缓存命中率高达 90% 以上**，恰好对应用户场景最大的成本痛点

二、核心价值：成本节省分析

2.1 Agent 的 Token 消耗结构

AI Agent 与传统 API 调用的最大区别在于：**Agent 消耗的 Token 中，输入占绝对大头。**

一个典型的 Agent 任务链路：用户提问 → Agent 整理问题上下文 → 拼接系统提示词（规则、记忆、工作区信息） → 调用工具 → 读取工具返回结果 → 继续推理...

每次 Agent 交互，AI 要"阅读"大量上下文才能保证结果准确。**输入 Token 消耗通常是输出的 5-10 倍。**

2.2 DeepSeek 缓存机制：直接命中成本痛点

DeepSeek 官方提供了 **上下文缓存（Context Caching）** 机制。系统提示词（system prompt）中稳定不变的部分会自动命中缓存，**缓存命中的输入价格仅为正常价格的 3% 左右。**

模型	正常输入价	缓存命中价	输出价
deepseek-v4-pro	9 元/百万 tokens	0.3 元/百万 tokens	27 元/百万 tokens
deepseek-v4-flash	3 元/百万 tokens	0.1 元/百万 tokens	9 元/百万 tokens

BC Agent Desktop 的技术架构，就是为了最大化这个缓存命中率而设计的。

2.3 成本对比：自建 vs Trae Work

场景假设：一个 10 人团队，每人每天处理 20 个 Agent 任务，每个任务平均输入 50K tokens、输出 10K tokens。

方案	月成本	计算方式
Trae Work 付费套餐	¥499/月	¥49.9 × 10 人
自建 + deepseek-v4-flash	≈ ¥125/月	见下方明细
自建 + deepseek-v4-pro	≈ ¥350/月	见下方明细

自建方案成本明细（deepseek-v4-flash，缓存命中率 90%）：

月输入 tokens = 10人 × 20任务 × 50K × 22天 = 220,000,000 tokens
有效输入成本 = 220M × (10% × 3元 + 90% × 0.1元) / 1,000,000
= 220 × (0.3 + 0.09) = 220 × 0.39 = 85.8 元

月输出 tokens = 10人 × 20任务 × 10K × 22天 = 44,000,000 tokens
输出成本 = 44 × 9元 / 1,000,000 = 39.6 元

月总成本 ≈ 85.8 + 39.6 ≈ 125.4 元

自建方案成本明细（deepseek-v4-pro，缓存命中率 90%）：

有效输入成本 = $220 \times (10\% \times 9 + 90\% \times 0.3) = 220 \times (0.9 + 0.27) = 220 \times 1.17 = 257.4$ 元
输出成本 = $44 \times 27 = 118.8$ 元
月总成本 ≈ 376.2 元 （实际约 350 元，因简单任务可切 flash）

2.4 成本节省总结

对比维度	Trae Work	自建方案	节省
10 人团队月费	¥499	¥125~350	25%~75%
50 人团队月费 (预计规模)	¥2,495	¥585~1,755	30%~77%
100 人团队月费	¥4,990	¥1,170~3,510	30%~77%
是否有排队	高峰期排队	无排队	—
是否有平台政策风险	随时涨价/限流	完全可控	—
是否可扩展业务系统	不可扩展	可对接	—

结论：自建方案不仅成本更低，而且团队规模越大、使用频率越高，节省越明显。**更重要的是，这是买断式的技术资产，不是租赁式的消耗品。**

三、方案设计：先降本，后建平台

3.1 总体策略：分两步走

第一步（当前）→ 单用户桌面版

- 目标：立竿见影降成本
- 形态：个人安装的桌面应用
- 模型：绑定 DeepSeek API Key
- 核心：最大化缓存命中率 → 最小化 Token 成本

第二步（后续）→ 企业多用户版

- 目标：企业级 AI 基础设施
- 形态：服务端部署 + 多用户接入
- 模型：深度对接公司业务系统（审批系统/业务系统/知识库...）
- 核心：权限管理、技能管理、组织架构

为什么先做单用户版？

- 1. **降成本是当前最紧迫的需求** — 单用户版可以直接复用 DeepSeek 缓存机制，马上见效
- 2. **单用户版 0 服务器成本** — 纯本地运行，不需要部署维护任何后端服务
- 3. **快速交付** — 不做多用户、不做权限、不做审核流，聚焦核心能力
- 4. **为多用户版铺路** — 单用户版的核心插件和架构，到多用户版可以直接复用

3.2 单用户版核心功能

功能	价值	对降成本的贡献
智能会话	绑定自己的 DeepSeek Key，走缓存通道	输入成本降低 87%
规则管理	行为规则稳定注入 system prompt，保持缓存命中	维持高缓存命中率
记忆管理	工作区记忆持续累积，AI 无需重复读取上下文	减少无效输入 Token
工作区管理	按项目隔离上下文，同项目内缓存复用	多项目间缓存不污染
技能系统	安装第三方技能扩展 AI 能力	逐步替代 Trae Work 功能
定时任务	AI 按计划自动执行（日报/周报/监控）	释放人力，减少交互成本

3.3 技术架构



架构特点：

- 上游零修改：AI 引擎以 npm 依赖锁定版本，不修改上游代码，随时可升级
- 插件化扩展：所有业务功能以插件形式开发，未来多用户版直接复用
- 数据本地存储：凭证、会话、记忆全部存本地，不出本机

3.4 为什么 DeepSeek 官方 Harness 能实现 90%+ 缓存命中率

DeepSeek 的上下文缓存机制对 Agent 场景有天然优势：

缓存友好因素	说明
系统提示词稳定	规则、记忆、工作区描述等是相对稳定的，一旦设定不会频繁变化
前缀缓存机制	DeepSeek 以请求前缀为缓存 key，相同前缀自动命中，不额外收费
工作区隔离	同一工作区内的会话共享相同的前缀，缓存利用率极高
规则/记忆注入稳定化	我们通过 system-prompt 接缝注入，与对话内容分离，最大化缓存命中

对比其他方案：

方案	缓存命中率	输入成本	说明
Trae Work（自带模型）	不可知	按积分计费	排队、限流、不可控
直接调用 DeepSeek API（无缓存优化）	不可知	9 元/M tokens	没看到策略，纯按量付费
BC Agent（自建，缓存优化）	90%+	≈1.17 元/M tokens	充分利用缓存机制

四、与竞品对比

4.1 市场主流 Agent 工具对比

对比项	Trae Work	Claude Code	BC Agent（自建）
费用	免费额度缩水 / ¥49.9/月	API Key 费用	仅需 API Key 费用
绑定自有 DeepSeek 模型	✅ 支持	✅ 可绑定	✅ 原生支持，最优缓存
缓存降本	不可控	不可控	✅ 90%+ 缓存命中率
企业数据安全	❌ 数据经过平台	✅ 全本地	✅ 全本地
排队	高峰期排队	无排队	无排队
对接业务系统	❌ 不可扩展	❌ 不可扩展	✅ 可扩展
开源可控	❌	❌	✅ 开源
品牌白标	❌	❌	✅ 支持

4.2 各模型供应商价格对比（2026-08）

模型	输入价	缓存命中价	输出价	能力排名
kimi-k3	20	2	100	1
deepseek-v4-pro	9	0.3	27	2
GLM-5.3	8	2	28	3
qwen3.8-max	12	1.5	36	4
Doubao_Seed_2.1_pro	6	1.2	30	5
deepseek-v4-flash	3	0.1	9	6
MiniMax-M3	3.15	0.63	12.6	7
Doubao_Seed_2.1_turbo	3	0.6	15	8

DeepSeek 的缓存命中价比所有竞品都低一个数量级，这是自建方案最大的成本优势来源。

五、后续演进方向

5.1 短期（1-2 个月）：单用户桌面版上线

- 完成桌面壳和核心 UI 开发
- 规则管理、记忆管理、定时任务上线
- 团队内部试用，验证缓存命中率和成本节省效果

5.2 中期（3-6 个月）：对接公司业务系统

通过技能系统扩展，使 AI Agent 具备企业级能力：

业务系统	对接方式	价值
CRM 客户系统	开发查询技能	销售团队快速获取客户信息
内部知识库	开发检索技能	AI 基于企业知识回答问题
工单/审批系统	开发提交技能	自动化提交流程、催办
数据报表系统	开发分析技能	定时生成业务报表

5.3 长期（6-12 个月）：企业多用户版

- 从单用户桌面版演进为多用户服务端部署
- 引入组织架构、权限管理、审核流程
- 成为企业内部的 AI 智能体基础设施

六、为什么选 DeepSeek：其他模型做不到这么低的成本

6.1 缓存命中率是核心差异

DeepSeek 的上下文缓存机制是本次自建方案**成本优势的根基**。其他模型虽然也提供缓存能力，但价格和效果差距明显：

模型	正常输入价	缓存命中价	缓存价降幅	备注
deepseek-v4-pro	9	0.3	-97%	缓存命中价最低
deepseek-v4-flash	3	0.1	-97%	轻量场景极致性价比
kimi-k3	20	2	-90%	缓存价仍是 deepseek 的 6.7 倍
GLM-5.3	8	2	-75%	缓存价是 deepseek 的 6.7 倍

模型	正常输入价	缓存命中价	缓存价降幅	备注
qwen3.8-max	12	1.5	-87.5%	缓存价是 deepseek 的 5 倍
Doubao_Seed_2.1_pro	6	1.2	-80%	缓存价是 deepseek 的 4 倍
MiniMax-M3	3.15	0.63	-80%	缓存价是 deepseek 的 2.1 倍

关键数据：deepseek-v4-flash 的缓存命中价（0.1 元/百万 tokens）是市面上所有模型中最低的，仅为第二名 MiniMax-M3 的 **1/6**。即使不做任何缓存优化，deepseek-v4-flash 的正常输入价（3 元）也低于大多数模型的缓存命中价。

6.2 DeepSeek Harness + DeepSeek 模型 = 最优组合

deepseek-harness 是 DeepSeek 官方开源，对自家模型的缓存机制做了最充分的适配：

- **协议级优化：**Harness 与 DeepSeek API 之间的缓存协商是原生支持的，无需额外适配
- **前缀一致性：**Harness 的 system-prompt 注入机制与 DeepSeek 的缓存 key 设计天然对齐
- **升级同步：**Harness 与 DeepSeek 模型能力同步演进，不会出现第三方 Harness 适配滞后的问题

如果用其他模型（如 Kimi、GLM），即使缓存命中率做到 90%，缓存命中价也远高于 DeepSeek 的缓存价，**成本优势会大打折扣。**

6.3 即使不用缓存，DeepSeek 依然是最优选择

对比项	deepseek-v4-flash	其他模型最低价
正常输入价	3 元/百万 tokens	3 元（MiniMax-M3） / 最低
缓存命中价	0.1 元/百万 tokens	0.63 元（MiniMax-M3）
如需更强能力	切 v4-pro（9 元，排名第 2）	kimi-k3（20 元，排名第 1）

结论：DeepSeek 是目前唯一同时满足「能力强、价格低、缓存命中价极低、官方 Harness 原生适配」四个条件的模型方案。这是我们选择 DeepSeek 路线的核心原因。

七、总结

我们为什么要做这件事？

1. **降成本是刚需** — DeepSeek 90%+ 的缓存命中率，让输入成本从 9 元降到 1.17 元/M tokens，这是我们自建方案最核心的护城河
2. **摆脱平台依赖** — Trae Work 的免费额度在缩、付费在涨，今天不布局，明天被动
3. **业务部门也在快速接入** — 从现在的少数业务用户，到预计 50 人以上，越早自建，节省越多
4. **掌握主动权** — 开源方案完全可控，后续可平滑扩展为企业级 AI 基础设施

第一步做什么？

不做大而全，先做**单用户桌面版**。核心目标只有一个：用 DeepSeek 的缓存机制，把 AI Agent 的使用成本降到最低。先跑通、先省钱、先验证，再扩展。

一句话总结：

花两个月做一个我们自己的 AI Agent 底座，用 DeepSeek 90% 的缓存命中率把 Token 成本打下来，从此不再看任何平台的脸色。后续可以用这套底座，对接公司所有业务系统，从成本中心变成效率中心。